เทคโนโลยี • บทความวิชาการ

การประมวลผลภาษาธรรมชาติสำหรับภาษาไทย

ความท้าทายของการตัดคำในภาษาที่ไม่เว้นวรรคระหว่างคำ

กองบรรณาธิการ ราชบัณฑิตยสภา
สำนักวิทยาศาสตร์

๒๗ ม.ค. ๒๕๖๙ ๖ ก.พ. ๒๕๖๙ อ่าน ๗ นาที

ความนำ

การประมวลผลภาษาธรรมชาติ (natural language processing)
คือการทำให้คอมพิวเตอร์วิเคราะห์และสร้างภาษาที่มนุษย์ใช้ได้
งานประเภทนี้อยู่เบื้องหลังเครื่องมือที่ใช้กันทั่วไป เช่น ระบบค้นหา การแปลภาษาด้วยเครื่อง
และการแปลงเสียงพูดเป็นข้อความ สำหรับภาษาไทย
ขั้นตอนพื้นฐานที่สุดอย่างหนึ่งกลับเป็นความท้าทายสำคัญ นั่นคือการตัดคำ

ทำไมต้องตัดคำ

ภาษาไทยเขียนคำต่อเนื่องกันโดยไม่เว้นวรรคระหว่างคำ การเว้นวรรคใช้เพื่อแบ่งวลีหรือประโยค ไม่ใช่เพื่อแบ่งคำ ขณะที่ระบบประมวลผลภาษาส่วนใหญ่ต้องเริ่มจากหน่วยคำ เช่น การนับความถี่ของคำ การค้นหา หรือการแปล หากตัดคำผิด ขั้นตอนถัดไปทั้งหมดก็จะผิดตามไปด้วย

ความกำกวม

ข้อความเดียวกันอาจตัดคำได้หลายแบบ และให้ความหมายต่างกัน ตัวอย่างที่มักยกมาอธิบาย เช่น

ข้อความ	การตัดคำแบบที่ ๑	การตัดคำแบบที่ ๒
ตากลม	ตา | กลม	ตาก | ลม
ไปหามเหสี	ไป | หา | มเหสี	ไป | หาม | เหสี

มนุษย์ใช้บริบทตัดสินว่าแบบใดถูกต้องได้โดยแทบไม่รู้ตัว แต่คอมพิวเตอร์ต้องอาศัยพจนานุกรม สถิติ หรือแบบจำลองที่เรียนรู้จากข้อมูล นอกจากนี้ยังมีปัญหาคำที่ไม่อยู่ในพจนานุกรม เช่น ชื่อเฉพาะ คำทับศัพท์ คำสแลง และคำที่สะกดผิด

แนวทางการตัดคำ

1. อาศัยพจนานุกรม เช่น การเลือกคำที่ยาวที่สุดที่ตรงกับพจนานุกรม
   หรือการเลือกแบบที่ได้จำนวนคำน้อยที่สุด วิธีนี้เข้าใจง่ายและรวดเร็ว แต่จัดการกับคำใหม่ได้ไม่ดี
2. อาศัยการเรียนรู้ของเครื่อง โดยฝึกแบบจำลองจากคลังข้อความที่มนุษย์ตัดคำไว้แล้ว
   ให้ตัดสินว่าตำแหน่งใดเป็นขอบเขตของคำ
3. อาศัยแบบจำลองโครงข่ายประสาทเทียม ซึ่งเรียนรู้รูปแบบจากระดับตัวอักษร
   และรับมือกับคำที่ไม่เคยพบได้ดีขึ้น

ความแม่นยำของวิธีที่อาศัยข้อมูลขึ้นอยู่กับคลังข้อความที่ใช้ฝึกเป็นอย่างมาก หน่วยงานในประเทศ เช่น ศูนย์เทคโนโลยีอิเล็กทรอนิกส์และคอมพิวเตอร์แห่งชาติ ได้พัฒนาคลังข้อความภาษาไทยเพื่อใช้ในงานวิจัยด้านนี้ ปัญหาที่ยังพบคือ หลักการตัดคำของแต่ละคลังอาจไม่เหมือนกัน เช่น คำประสมควรนับเป็นคำเดียวหรือหลายคำ

ความท้าทายอื่นของภาษาไทย

- การแบ่งประโยค ภาษาไทยไม่มีเครื่องหมายมหัพภาคเป็นหลักในการจบประโยค
  การเว้นวรรคจึงต้องตีความว่าเป็นการจบประโยคหรือไม่
- รูปเขียนหลายแบบ คำทับศัพท์คำเดียวกันอาจสะกดต่างกัน การใช้หลักเกณฑ์การทับศัพท์ช่วยลดปัญหานี้ได้

- การเรียงอักขระ ข้อความที่พิมพ์สระและวรรณยุกต์สลับลำดับกัน อาจดูเหมือนกันบนจอแต่คอมพิวเตอร์มองว่าต่างกัน

สรุป

การตัดคำเป็นพื้นฐานของการประมวลผลภาษาไทย และเป็นปัญหาที่ยังมีการพัฒนาอย่างต่อเนื่อง ความร่วมมือระหว่างนักภาษาศาสตร์และนักคอมพิวเตอร์ รวมถึงการมีพจนานุกรมและหลักเกณฑ์ทางภาษาที่เป็นมาตรฐาน มีส่วนสำคัญในการทำให้เทคโนโลยีภาษาไทยมีคุณภาพมากขึ้น

เอกสารอ้างอิง

1. ศูนย์เทคโนโลยีอิเล็กทรอนิกส์และคอมพิวเตอร์แห่งชาติ (เนคเทค). *เว็บไซต์เนคเทค*. https://www.nectec.or.th/
2. ราชบัณฑิตยสถาน. (๒๕๕๖). *พจนานุกรม ฉบับราชบัณฑิตยสถาน พ.ศ. ๒๕๕๔*. กรุงเทพฯ: ราชบัณฑิตยสถาน. https://dictionary.orst.go.th/
3. สำนักงานราชบัณฑิตยสภา. *ระบบฐานข้อมูลคำทับศัพท์*. https://transliteration.orst.go.th/

อ้างอิงบทความนี้

APA MLA Chicago

กองบรรณาธิการ ราชบัณฑิตยสภา. (๒๕๖๙, ๒๗ มกราคม). *การประมวลผลภาษาธรรมชาติสำหรับภาษาไทย*. ราชบัณฑิตยสภา. https://royalsociety.go.th/pages/article.html?id=kn-technology-๒๐๒๖-๐๑-๒๗

คัดลอกการอ้างอิง